

# Estimación del Gradiente en Perceptrones Multicapa

Juan David Velásquez Henao

[jvelasq@unal.edu.co](mailto:jvelasq@unal.edu.co)

Universidad Nacional de Colombia, Sede Medellín

Facultad de Minas

Medellín, Colombia

---

Haga clic [aquí](#) para acceder al repositorio online.

---

A continuación, se realiza la derivación del gradiente para un perceptrón multicapa.

SUPUESTOS USADOS EN LA DERIVACIÓN DEL GRADIENTE DE LA FUNCIÓN DE ERROR:

1. Se limita un máximo de 3 capas de procesamiento (2 capas ocultas)
2. Ecuaciones para perceptrones más simples (menos capas) se obtienen directamente de la formulación.
3. Los contadores para las capas de procesamiento 0, 1, 2 y 3 son  $i, j, k$  y  $m$  respectivamente.
4.  $z_L[\cdot]$  es la salida de una neurona de la capa  $L$ . Si  $L$  es la última capa, entonces equivale a la salida del modelo.  $z_0[\cdot]$  es la entrada al perceptrón ( $x[\cdot]$ ).
5.  $a_L[\cdot]$  es la entrada a una neurona de la capa  $L$ .
6.  $w_L[\cdot, \cdot]$  son los pesos de la capa  $L - 1$  hacia la capa  $L$ .
7.  $b_L[\cdot]$  son los pesos de la neurona bias hacia cada una de las neuronas de procesamiento de la capa  $L$
8.  $z_L[\cdot] = \sigma_L(\cdot)$  es la activación de la neurona y  $\sigma'_L(\cdot)$  es su derivada para una neurona de la capa  $L$ .

ECUACIONES BÁSICAS:

$$a_L[\tau] = b_L[\tau] + \sum_{\kappa} w_L[\kappa, \tau] z_{L-1}[\kappa]; \quad z_L[\tau] = \sigma(a_L[\tau]); \quad \frac{\partial}{\partial a_L[\tau]} z_L[\tau] = \sigma'_L[\tau]; \quad \frac{\partial}{\partial w_L[\kappa, \tau]} a_L[\tau] = z_{L-1}[\kappa]$$

$$\frac{\partial}{\partial b_L[\kappa, \tau]} a_L[\tau] = 1; \quad \delta_L[\tau] = e_L[\tau] \sigma'_L[\tau]; \quad e_{L-1}[\tau] = \sum_{\kappa} \delta_L[\kappa] w_L[\tau, \kappa]$$

DERIVACIÓN ANALÍTICA DEL GRADIENTE:

$E()$  es el criterio de error utilizado. La derivación es independiente de la función específica utilizada. Por simplicidad se usará la sumatoria del error cuadrático para el patrón actual:

$$E_p = \frac{1}{2} \sum_{m=1}^M e_3[m]^2 = \sum_{m=1}^M (d[m] - z_3[m])^2$$

Entonces:

$$\frac{\partial}{\partial z_3[q]} E_p = \sum_{m=1}^M \frac{1}{2} \frac{\partial}{\partial z_3[q]} (d[m] - z_3[m])^2 = \sum_{m=1}^M e_3[m] \frac{\partial}{\partial z_3[q]} (d[m] - z_3[m])$$

La sumatoria anterior sólo es diferente de cero para  $q = m$ .

$$\frac{\partial E_p}{\partial z_3[m]} = -e_3[m]$$

Gradiente para la 3ª capa de procesamiento.

$$\begin{aligned}\frac{\partial}{\partial w_3[k,m]} E_p &= \left( \frac{\partial z_3[m]}{\partial z_3[m]} \frac{\partial a_3[m]}{\partial a_3[m]} \right) \frac{\partial E_p}{\partial w_3[k,m]} = \left( \frac{\partial a_3[m]}{\partial w_3[k,m]} \right) \left( \frac{\partial z_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial E_p}{\partial z_3[m]} \right) = (z_2[k]) (\sigma'_3[m]) (-e_3[m]) \\ &= - (e_3[m] \sigma'_3[m]) (z_2[k]) = -\delta_3[m] z_2[k]\end{aligned}$$

$$\frac{\partial}{\partial b_3[m]} E_p = \left( \frac{\partial z_3[m]}{\partial z_3[m]} \frac{\partial a_3[m]}{\partial a_3[m]} \right) \frac{\partial E_p}{\partial b_3[m]} = \left( \frac{\partial a_3[m]}{\partial b_3[m]} \right) \left( \frac{\partial z_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial E_p}{\partial z_3[m]} \right) = (1) (\sigma'_3[m]) (-e_3[m]) = -e_3[m] \sigma'_3[m] = -\delta_3[m]$$

Gradiente para la 2ª capa de procesamiento (note la estructura recursiva de las ecuaciones).

$$\begin{aligned}\frac{\partial}{\partial w_2[j,k]} E_p &= \sum_{m=1}^M \left( \frac{\partial z_3[m]}{\partial z_3[m]} \frac{\partial a_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial z_2[k]}{\partial z_2[k]} \frac{\partial a_2[k]}{\partial a_2[k]} \right) \frac{\partial E_p}{\partial w_2[j,k]} = \sum_{m=1}^M \left( \frac{\partial z_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial a_3[m]}{\partial z_2[k]} \right) \left( \frac{\partial z_2[k]}{\partial a_2[k]} \right) \left( \frac{\partial a_2[k]}{\partial w_2[j,k]} \right) \left( \frac{\partial E_p}{\partial z_3[m]} \right) \\ &= \sum_{m=1}^M (\sigma'_3[m]) (w_3[k,m]) (\sigma'_2[k]) (z_1[j]) (-e_3[m]) = -\sigma'_2[k] z_1[j] \sum_{m=1}^M (e_3[m] \sigma'_3[m]) w_3[k,m] \\ &= -\sigma'_2[k] z_1[j] \sum_{m=1}^M \delta_3[m] w_3[k,m] = -\sigma'_2[k] z_1[j] e_2[k] = -\delta_2[k] z_1[j]\end{aligned}$$

$$\frac{\partial}{\partial b_2[k]} E_p = -\delta_2[k]$$

Gradiente para la 1ª capa de procesamiento

$$\begin{aligned}\frac{\partial}{\partial w_1[i,j]} E_p &= \sum_k \sum_m \left( \frac{\partial z_3[m]}{\partial z_3[m]} \frac{\partial a_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial z_2[k]}{\partial z_2[k]} \frac{\partial a_2[k]}{\partial a_2[k]} \right) \left( \frac{\partial z_1[j]}{\partial z_1[j]} \frac{\partial a_1[j]}{\partial a_1[j]} \right) \frac{\partial E_p}{\partial w_1[i,j]} \\ &= \sum_k \sum_m \left( \frac{\partial z_3[m]}{\partial a_3[m]} \right) \left( \frac{\partial a_3[m]}{\partial z_2[k]} \right) \left( \frac{\partial z_2[k]}{\partial a_2[k]} \right) \left( \frac{\partial a_2[k]}{\partial z_1[j]} \right) \left( \frac{\partial z_1[j]}{\partial a_1[j]} \right) \left( \frac{\partial a_1[j]}{\partial w_1[i,j]} \right) \left( \frac{\partial E_p}{\partial z_3[m]} \right) \\ &= \sum_k \sum_m (\sigma'_3[m]) (w_3[k,m]) (\sigma'_2[k]) (w_2[j,k]) (\sigma'_1[j]) (z_0[i]) (-e_3[m]) \\ &= -\sum_k \sum_m (e_3[m] \sigma'_3[m]) (w_3[k,m]) (\sigma'_2[k]) (w_2[j,k]) (\sigma'_1[j]) (z_0[i]) \\ &= -\sum_k (\sigma'_2[k]) (w_2[j,k]) (\sigma'_1[j]) (z_0[i]) \sum_m (\delta_3[m]) (w_3[k,m]) = -\sum_k (\sigma'_2[k]) (w_2[j,k]) (\sigma'_1[j]) (z_0[i]) e_2[k] \\ &= -\sum_k (e_2[k] \sigma'_2[k]) (w_2[j,k]) (\sigma'_1[j]) (z_0[i]) = -\sigma'_1[j] z_0[i] \sum_k \delta_2[k] w_2[j,k] = -\sigma'_1[j] z_0[i] e_1[j] = -\delta_1[j] z_0[i]\end{aligned}$$

$$\frac{\partial}{\partial b_1[j]} E_p = -\delta_1[j]$$

Para un perceptrón de una sola capa de procesamiento (monocapa) con  $k$  entradas y  $m$  neuronas de salida:

$$\frac{\partial}{\partial w_3[k,m]} E(\cdot) = (\sigma'_3[m] z_2[k]) \frac{\partial E(\cdot)}{\partial z_3[m]} = -2 e[m] (\sigma'_3[m] x[k])$$

Regla de aprendizaje:

$$\mathbf{w}(t+1) = \mathbf{w}(t) - \mu \frac{\partial}{\partial \mathbf{w}(t)} E(\cdot)$$